BENSLIMANE Sarah
EL GUEDDARI Kawtar
EL OMARI BOUYA Lina

Projet de M8

Introduction à la science des données

Exploration des Déterminants de la Santé du Sommeil à Travers les Données

2023/2024

INSA Rouen

Table des matières

Introduction **3**
Description des données **4**
VARIABLES QUALITATIVES 4
VARIABLES QUANTITATIVES 5
ANALYSE DES COMPOSANTES PRINCIPALES (ACP) 7
Régressions **7**
RÉGRESSION SIMPLE 7
RÉGRESSION MULTIPLE 9
Tests Statistiques **10**
TEST DU Chi2 10
TEST ANOVA (FISHER) 11
TEST T DE STUDENT 12
Conclusion **14**
ANNEXES **15**

Introduction

Alors que nous étudions les nombreuses possibilités de projet, l'idée d'étudier les liens entre les habitudes quotidiennes et la qualité du sommeil a retenu notre attention. L'objectif principal de notre étude est de déterminer comment différents facteurs de style de vie influencent la qualité du sommeil, un sujet qui touche directement à la santé et au bien-être quotidien.

Nous avons commencé par une analyse descriptive des données pour comprendre la répartition et les tendances générales de chaque variable. Ensuite, nous avons appliqué des techniques analytiques telles que l'analyse en composantes principales (ACP) et divers modèles de régression, pour explorer les relations entre les variables et la qualité du sommeil. Pour évaluer l'impact des variables qualitatives, nous avons utilisé des tests statistiques notamment le test du χ_2 pour examiner la relation entre l'occupation et les troubles du sommeil.

Notre analyse vise à fournir une compréhension approfondie des facteurs influençant le sommeil et à identifier des comportements qui pourraient améliorer la qualité du sommeil. Les résultats obtenus pourraient offrir des recommandations pratiques précieuses sur les habitudes de vie à adopter pour favoriser un sommeil de meilleure qualité.

Nous avons décidé de nous répartir le travail de la façon suivante, en veillant à ce que chacune d'entre nous puisse participer à toutes les parties:

Kawtar	**Lina**	**Sarah**
Qualité du sommeil, IMC, activité physique et pression artérielle Régression simple Test d'ANOVA	Niveau de stress, fréquence cardiaque, nombre de pas et trouble du sommeil ACP Test du χ^2	Age, genre, durée du sommeil et occupation. Régression multiple Test de Student

Description des données

Notre analyse se concentre sur un ensemble de 374 observations avec 13 variables, comprenant à la fois des données qualitatives et quantitatives. La première variable personID n'est pas prise en compte puisqu'il s'agit simplement d'un identifiant unique pour chaque individu et n'apporte aucune information pour l'analyse statistique.

VARIABLES QUALITATIVES

BMI Category:
La variable qualitative **nominale**, "BMI Category", représente l'IMC des individus, décrivant leurs corpulences en 4 catégories: Normal, Normal Weight, Obese, Overweight. En remarquant que Normal et Normal Weight expriment la même idée, on fusionne ces deux catégories pour une meilleure analyse. Plus de la moitié de l'échantillon est de corpulence normale[1].

Gender:
La variable "gender" est qualitative nominale. On aura donc des personnes de genre masculin ou féminin. Il y a 185 femmes et 189 hommes. Il y a donc une répartition pratiquement équitable entre les deux genres.

Occupation:
Cette variable qualitative nominale représente les professions des personnes prises en compte pour l'étude. Elles sont réparties comme qui suit:

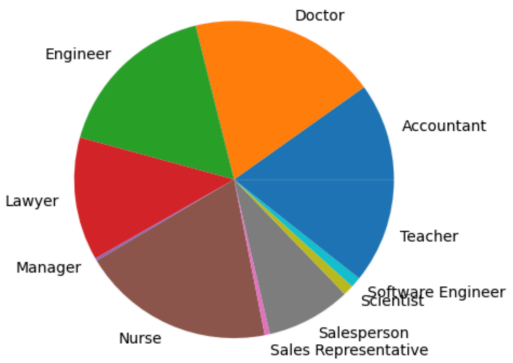

On remarque l'absence de personnes sans emploi. Si ces dernières avaient été prises en compte, on aurait pu avoir des résultats intéressants sur leur sommeil étant donné que la recherche d'emploi peut être source de stress.

Sleep Disorder
La variable qualitative nominale "sleep disorder" indique la présence ou l'absence de trouble du sommeil chez les individus concernés par l'étude. Elle se décompose en 3 catégories: aucun trouble du sommeil, insomnie ou bien apnée du sommeil.
Nous constatons que près de 42% du groupe étudié souffre de troubles du sommeil, ce qui est assez conséquent. Cela montre

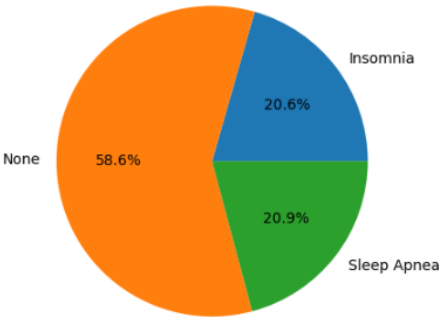

[1] Voir annexe 1

que ces troubles doivent être pris en compte pour la suite de l'étude.

VARIABLES QUANTITATIVES

Age:
La variable "age" représente l'âge de la personne en années. Par conséquent, elle est quantitative. On peut en extraire les informations suivantes:

minimum	27
maximum	59
moyenne	42.18449197860963
écart type	8.661530606217873
médiane	43

On remarque alors une dispersion modérée des valeurs. Néanmoins, l'âge étant compris entre 27 et 59, cela voudrait dire que le jeu de données ne prend pas en compte les personnes plus jeunes. Il aurait été intéressant de pouvoir comparer les données sur le sommeil des enfants à celles des adultes.

Blood Pressure (systolic/diastolic):
La pression artérielle est caractérisée par le rapport entre les pressions systoliques et diastoliques. Pour décrire cette variable, on étudie séparément ces deux pressions. En moyenne, les pressions systoliques et diastoliques sont respectivement de 128,6 et 84,6 mm/Hg. Ces dernières sont fortement liées avec un coefficient de corrélation proche de 0.97.

Physical Activity Level:
Cette variable quantitative **continue** représente la quantité d'activité physique réalisée par les individus en minutes par jour. On calcule un étendue interquartile de 30.0 ce qui traduit une distribution relativement symétrique et une dispersion modérée des valeurs centrales[2].

Sleep Duration:

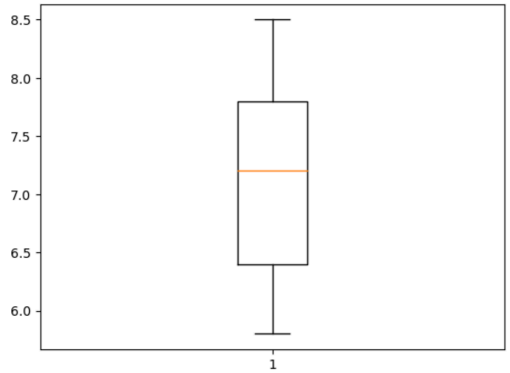

C'est le nombre d'heures de sommeil par jour. La variable est donc quantitative. On peut étudier ses caractéristiques grâce au boxplot suivant:

On remarque une médiane autour de 7 et une répartition des heures sur l'intervalle [5,8; 8,5].

[2] Voir annexe 2

Quality of Sleep:
Les individus évaluent leur sommeil avec une valeur allant de 1 à 10. La qualité du sommeil étant une variable quantitative **ordinale**, il est plus pertinent de calculer sa valeur médiane.

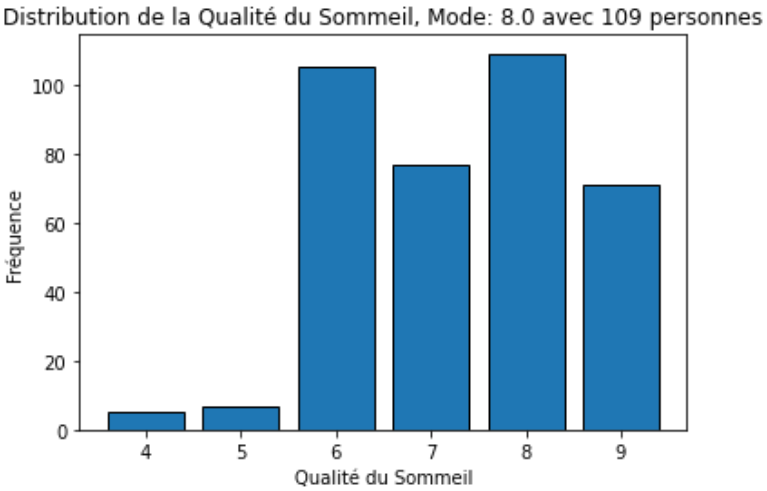

La qualité du sommeil est globalement bonne avec une médiane de 7 et une moyenne de 7,3. Cependant, la fréquence la plus élevée à 8 suggère que beaucoup de personnes rapportent une qualité de sommeil légèrement meilleure que la médiane, avec des variations autour de cette valeur moyenne légèrement supérieure.

Stress Level
Cette variable permet aux individus concernés par l'étude d'évaluer, par une note comprise entre 1 et 10, le niveau de stress qu'ils ressentent au quotidien. Les réponses vont de 3 à 10, c'est à dire que les niveaux de stress varient de modérément bas à modérément élevés; il n'y a pas de cas de stress extrêmement bas ni extrêmement élevé[3], ce qui montre un certain contrôle et gestion de la part des participants de l'enquête. La médiane (5.0) et la moyenne (5.38) sont assez proches, on peut donc en déduire que la distribution est relativement symétrique. En somme, les niveaux de stress sont assez concentrés autour de la moyenne, et il y a peu de variations extrêmes.

Heart Rate: Cette variable se concentre sur la fréquence cardiaque au repos en battements par minute (bpm). La médiane (70) et la moyenne (70.1) sont proches donc la distribution est symétrique. Généralement le cœur bat entre 60 et 100 fois[4] par minute, et les valeurs de l'étude étant comprises entre 65 et 86, cela indique que la majorité des individus de l'échantillon présentent une fréquence cardiaque au repos dans la plage normale, suggérant une bonne santé cardiaque globale dans le groupe d'étude.

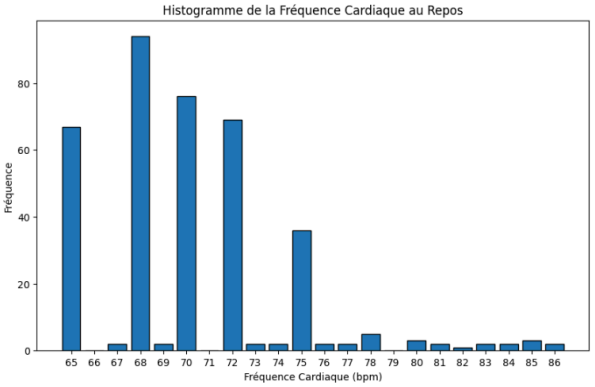

[3] Voir histogramme en annexe 3
[4] https://www.cardiosecur.com/fr/magazine/articles-specialises/notions-de-base-sur-le-coeur/coeur-en-bonne-sante

Daily steps
Cette variable quantifie le nombre de pas effectués par jour. Après les calculs nécessaires, on constate que le nombre de pas quotidiens varie entre 3000 et 10000. On obtient une moyenne de 6816 pas et une médiane de 7000 pas, ce qui prouve une distribution assez symétrique. Les pas sont donc concentrés autour de la moyenne, avec toutefois un écart-type de 1615, montrant ainsi une variation modérée. En résumé, ces grandeurs montrent une assez grande diversité dans les niveaux d'activité physiques des individus, allant de modérément actifs à très actifs[5].

ANALYSE DES COMPOSANTES PRINCIPALES (ACP)

Dans le cas de notre étude, nous avons réalisé une ACP. Pour y parvenir, nous avons extrait les variables quantitatives. En plus de permettre la réduction de la dimensionnalité des données tout en préservant l'essentiel de l'information, l'ACP nous a permis de transformer les variables numériques en composantes principales. Ainsi, cela nous a permis de réduire le nombre de dimensions à considérer. Nous avons projeté les données sur les deux premiers composants principaux, qui expliquent une grande partie de la variance dans les données.

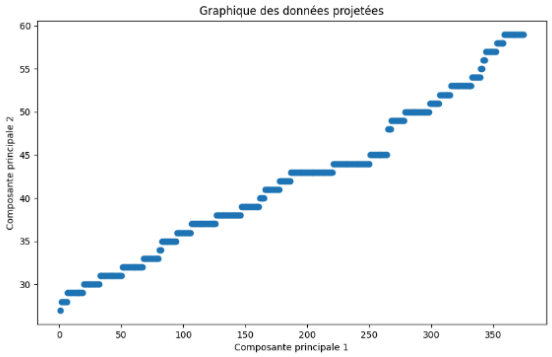

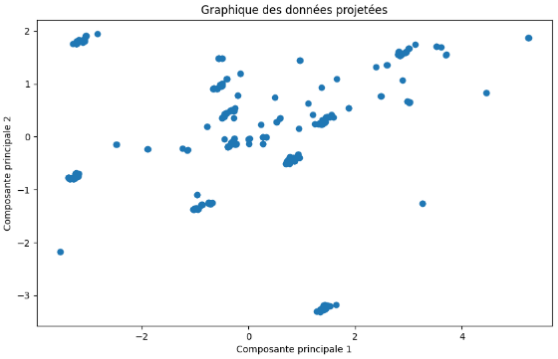

Comme le montrent les deux graphiques avant et après, l'ACP a permis de transformer les données en un espace beaucoup plus représentatif. Les données projetées montrent une dispersion qui maximise la variance le long des deux premières composantes principales.

Régressions

RÉGRESSION SIMPLE

Nous souhaitons répondre à la question: Dans quelle mesure l'activité physique influence-t-elle la durée du sommeil ?
Tout d'abord, il est pertinent de visualiser la relation entre ces deux variables en traçant l'activité physique en fonction de la durée de sommeil[6]. On peut alors considérer un modèle de régression linéaire puisqu'une relation apparente existe.
On trace, ainsi, la droite de régression $y = ax + b$ avec $a = 0,008$ et $b = 6,65$.

[5] Voir histogramme en annexe 4
[6] Voir annexe 5

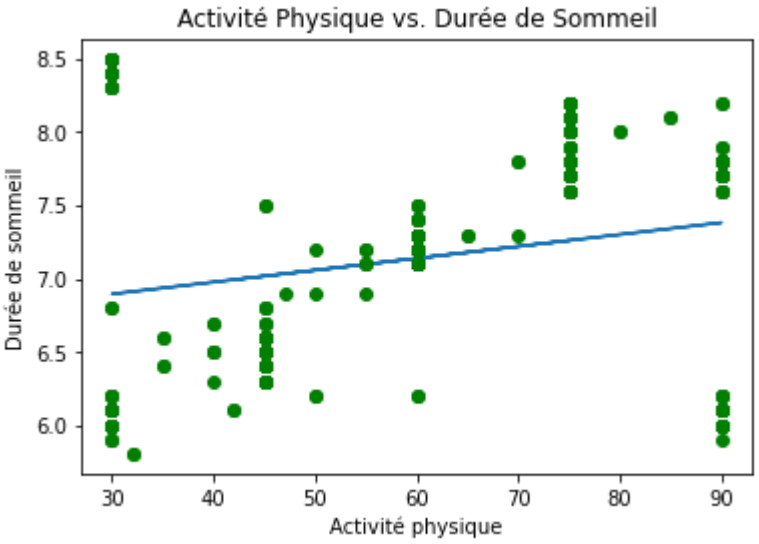

On remarque que cette droite ne semble pas s'ajuster aux données réelles, aussi suggérée par la faible pente de régression. De plus le coefficient de détermination R^2 = 0.045, proche de 0 confirme une mauvaise adéquation du modèle aux données. Cependant, des points aberrants semblent tirer la droite vers eux.

Pour vérifier cette hypothèse, on peut calculer les résidus de la régression[7]. On obtient une sorte de gaussienne avec une moyenne des résidus à 9.28e-15 soit très proche de 0. Mais certaines barres significativement plus basses, indiquent des observations qui ne suivent pas la tendance générale des données. Il est aussi utile de calculer les contributions de chaque observation dont le graphique confirme une plus grosse influence des dernières observations sur la régression.

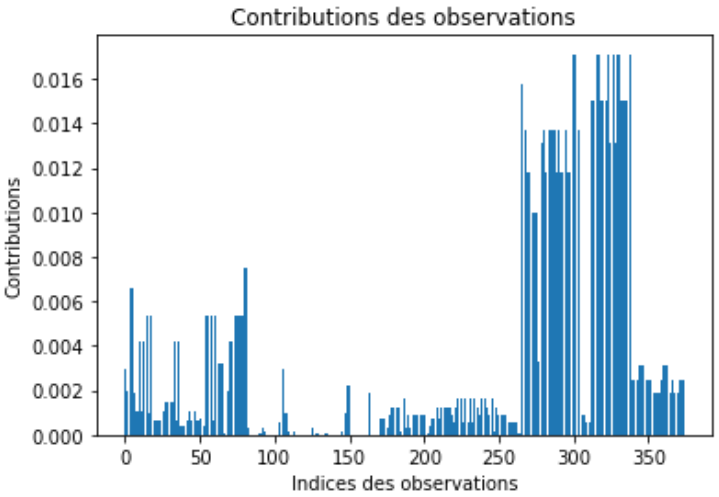

On décide alors de filtrer les observations en filtrant celles dont les contributions sont supérieures à $\frac{4}{n}$[8]. Cela revient à supprimer 16% des données, passant de 374 à 314 observations ce qui peut réduire la précision et la fiabilité du modèle. Néanmoins, cela permet d'améliorer significativement le modèle puisque le nouveau coefficient de détermination est de R^2 = 0.74.

[7] Histogramme des résidus de la régression en annexe 6
[8] Dans le but de mettre de côté les observations dont l'influence est conséquente par rapport à la taille de l'échantillon

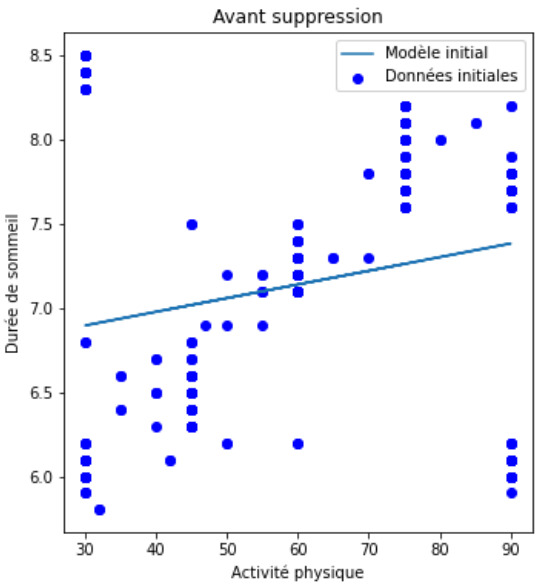

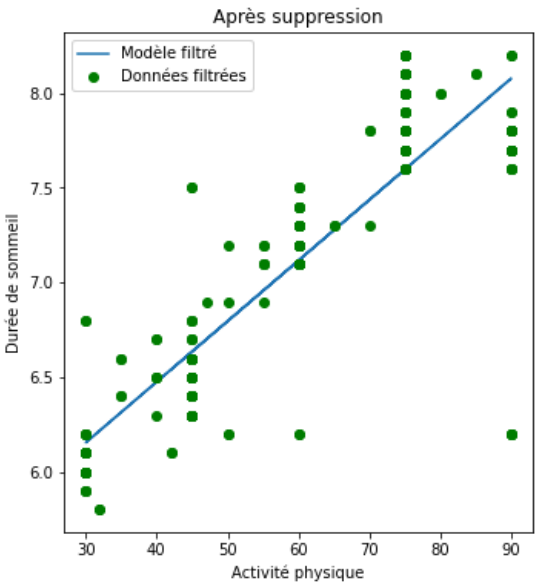

On observe que la droite de régression s'ajuste beaucoup mieux aux données validant, ainsi, le modèle de régression linéaire. On peut conclure que l'activité physique a une influence significative sur la durée du sommeil et qu'avec nos données filtrées, 74% de la variation observée dans la durée du sommeil peut être expliquée par les variations de l'activité physique mesurées.

RÉGRESSION MULTIPLE

Pour la partie sur les régression linéaires, nous avons décidé d'étudier les facteurs influençant le plus sur la qualité du sommeil. Pour cela nous avons procédé à l'évaluation des Cp de mallows par forward selection.

Tout d'abord il a fallu construire une nouvelle matrice *data_new* afin de pouvoir effectuer notre étude sur des variables quantitatives uniquement. Par conséquent, nous avons retiré les variables 2, 4, 9, et 13 car elles sont toutes qualitatives. Nous avons également enlevé la variable 1 correspondant à l'ID de chaque personne car ce nombre n'est pas pertinent pour notre étude. En plus, nous avons décidé de ne pas prendre en compte la variable Blood Pressure car elle se compose de deux nombres différents. Finalement, nous avons choisi notre 'y' qui correspond à la variable 6, c'est-à-dire, la qualité du sommeil.

Après avoir obtenu la matrice de données *data_new,* nous avons effectué un boxplot qui nous a permis de voir une grande différence de grandeur entre la variable Daily steps et le reste des variables. En effet, elle est de l'ordre 10^3 . Par la suite, il a fallu procéder à une normalisation des données qui a abouti à la matrice *data_new_norm.* Le dernier changement à effectuer pour préparer nos données pour la forward selection a été de transformer le type de y d'objet à float64 sinon la régression n'aurait pas marché.

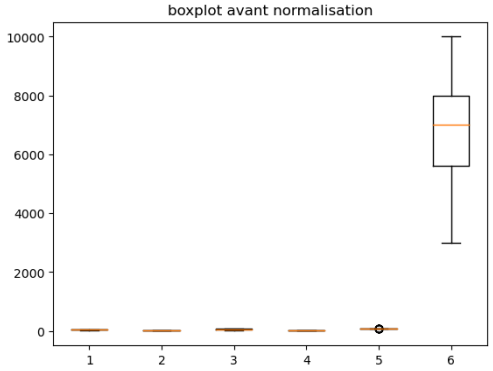

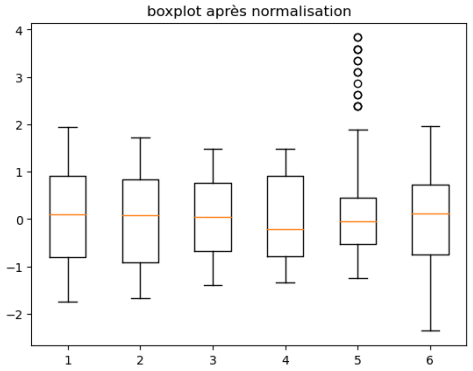

Après l'exécution de notre code, nous avons obtenu un classement décroissant des variables selon le Cp de mallows le plus petit pour chaque tour comme qui suit:

Variable gagnante pour le tour 0 : 3 (Stress Level) et un Cp de 406.09617844419324
Variable gagnante pour le tour 1 : 1 (Sleep Duration) et un Cp de 127.23948808260582
Variable gagnante pour le tour 2 : 5 (Daily Steps) et un Cp de 50.9170990478529
Variable gagnante pour le tour 3 : 0 (Age) et un Cp de 25.72260754052354
Variable gagnante pour le tour 4 : 4 (Heart Rate) et un Cp de 5.112181555893471
Variable gagnante pour le tour 5 : 2 (Physical Activity Level) et un Cp de 6.9999999999998295

Nous avons donc remarqué une légère hausse au niveau du CP de Mallows pour la variable du dernier tour. Il aurait été contre-productif de la garder pour la régression multiple. Par conséquent, une dernière matrice appelée *data reg* a été créée afin de contenir les 5 variables qui nous intéressaient dans l'ordre de leur importance. Finalement, la régression correspondant à à cette matrice et à la qualité du sommeil a été effectuée et a abouti à un R2 de 0.903462815994335, ce qui est plutôt satisfaisant.

Tests Statistiques

TEST DU χ_2

Les troubles du sommeil sont un problème de santé publique nécessitant une attention particulière. Dans un monde où le travail occupe de plus en plus de place dans la vie des individus, nous pouvons nous interroger sur l'impact de ce dernier sur le sommeil, et plus précisément sur les troubles du sommeil.
Étant donné que nous sommes confrontés à deux variables catégorielles, on fait appel au test du χ^2 d'indépendance.
Tout d'abord, il est nécessaire d'émettre les hypothèses de l'étude:
Hypothèse nulle H_0: L'occupation et les troubles du sommeil sont des variables indépendantes.
Hypothèse alternative H_1: L'occupation et les troubles du sommeil sont des variables dépendantes.

Après avoir défini nos hypothèses initiales, nous avons dressé un tableau de contingence, à partir duquel nous avons émis les valeurs théoriques sous hypothèse d'indépendance. Pour

permettre ces calculs, nous avons associé une valeur ε proche de 0 à la modalité “None”, afin d’éviter les divisions par 0, ce qui pourrait fausser nos résultats. A partir de cela, nous avons défini le seuil de risque à $\alpha = 0.05$.

Nous avons d’abord calculé la distance du χ^2 entre les observations et le cas théorique:

$D(O,T) = \sum_{i=1}^{I}\sum_{j=1}^{J}\frac{(O_{ij}-T_{ij})^2}{T_{ij}}$ avec O_{ij} les effectifs observés et T_{ij} les effectifs théoriques.

Ensuite, nous déterminons le nombre de degrés de liberté du χ^2 ainsi que la $p - valeur$

Les résultats sont les suivants: $\chi^2 = 421,3$ et $p - valeur = 7,48 \times 10^{-77}$.

On constate une distance χ^2 relativement élevée, ce qui indique une différence conséquente entre les fréquences observées et les fréquences attendues sous l’hypothèse d’indépendance. De plus, la $p - valeur$ est inférieure au seuil de risque α, de ce fait, nous rejetons l’hypothèse H_0, et donc nous pouvons en conclure qu’il existe bien une certaine dépendance entre l’occupation professionnelle d’un individu et ses troubles du sommeil. En d’autres termes, certaines professions sont susceptibles de créer des troubles du sommeil chez l’individu. Intéressons nous à ces professions.[9]

On constate que la profession la plus touchée sont les représentants commerciaux, avec 100% des employés qui souffrent d’un trouble du sommeil. Néanmoins ce résultat n’est pas représentatif car on trouve uniquement 2 personnes qui exercent cette profession dans le cadre de l’étude. Il en va de même pour les ingénieurs logiciel, les scientifiques et les managers, qui sont très peu représentés dans l’échantillon. Cependant, parmi les professions largement représentées dans la base de données comme les enseignants et les infirmiers, on constate une forte présence de troubles du sommeil. Pour les infirmiers, on peut expliquer cela par les horaires de travail irréguliers, avec notamment du travail de nuit, qui peut grandement perturber le cycle naturel et troubler le sommeil des individus. Il s’agit également d’une profession exposée au stress, à la pression ou encore à la fatigue, facteurs qui jouent un rôle important dans le cadre du sommeil.[10] En ce qui concerne les enseignants, ils ont souvent une charge de travail conséquente, qui s’accompagne de responsabilités importantes. A cela, on peut ajouter les heures de travail supplémentaires qui prolongent les journées, dédiées notamment à la correction de travaux ou à la préparation de cours, ce qui réduit leur temps de repos. [11]

TEST ANOVA (FISHER)

On souhaite comparer les différences du nombre de pas moyen entre les groupes d'âge. On sépare ainsi l'échantillon en 3 groupes: les 27-39 ans avec un nombre de pas moyen μ_1, les 40-49 ans avec μ_2 et les 50-59 ans avec $\mu 3$. Existe-il une différence significative dans le

[9] cf. Annexe 7

[10] The impact of night shift stress and sleep disturbance on nurses quality of life: https://bmcnurs.biomedcentral.com/articles/10.1186/s12912-023-01673-3

[11] The impact of Sleep Deprivation in Teachers: https://amerisleep.com/blog/sleep-deprivation-in-teachers/

nombre de pas moyen entre les groupes d'âge ? Pour répondre à cette question nous choisissons un test ANOVA suivant la loi de Fisher.

Posons nos hypothèses:
Hypothèse nulle H_0: Il n'existe pas de différence: $\mu_1 = \mu_2 = \mu_3$.

Hypothèse alternative H_1: Au moins une paire est différente: $\mu_i \neq \mu_j$.
Il s'agit donc d'un test bilatéral. On choisit un seuil de risque $\alpha = 0.05$, c'est-à-dire que l'on a 5% de risque de rejeter H0 a tort.
La F-statistique se calcule en faisant le rapport de la moyenne des carrés entre les groupes sur la moyenne des carrés à l'intérieur des groupes:

$$F = \frac{SCT_{inter}}{k-1} / \frac{SCT_{intra}}{N-k}$$

On obtient alors $F = 0.74$ et la $p - valeur = 0.48$. Ainsi, $p - valeur > \alpha$ donc on ne rejette pas l'hypothèse H_0. Les données ne nous fournissent pas suffisamment de preuves pour suggérer que l'âge a un effet sur le nombre de pas moyen des individus dans les groupes d'âge étudiés. Cela peut s'expliquer par une homogénéité dans les différents groupes d'âge ou un échantillon trop petit. Il serait pertinent de comparer avec des groupes d'âge plus éloignés. De plus, les individus peuvent adapter leur comportement en vieillissant, en augmentant ou en maintenant leur niveau d'activité physique pour des raisons de santé, ce qui peut homogénéiser le nombre de pas moyen entre les groupes d'âge.

TEST T DE STUDENT

Les femmes ont-elles besoin de plus de sommeil que les hommes? Afin de répondre à cette question, nous allons établir la dépendance ou non de la durée de sommeil et du genre.
Le genre étant une variable qualitative et la durée du sommeil une variable quantitative, notre choix de test statistique s'est porté sur le t-test de student (test bilatéral). Pour commencer, posons nos hypothèses:

Hypothèse nulle H_0: indépendance du genre et du sommeil.
Hypothèse alternative H_1: dépendance du genre et du sommeil.

Nous cherchons à calculer la p-valeur correspondante. Si jamais cette dernière est inférieur au seuil de risque défini à 0.05, alors l'hypothèse H_0 sera rejetée. Nous utilisons la formule suivante:

$$\text{p-valeur} = 2 \cdot (1 - F_t(|t|, df))$$

avec $t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$, df le degré de liberté

et Sp^2 l'estimateur de la variance.

Après avoir effectué ces calculs, nous obtenons une p-valeur de 0.0187 < 0.05 et donc l'hypothèse nulle est rejetée. Par conséquent, le genre et le sommeil ne sont pas indépendants.

En comparant les moyennes de durée de sommeil des hommes et des femmes, nous trouvons que celle des femmes est à 7.23 alors que celle des hommes à 7.04. Les femmes auraient donc besoin d'un peu plus de sommeil. Mais pourquoi de tels résultats?

Les femmes dorment généralement plus et se couchent plus tôt que les hommes, passant également plus de temps en sommeil profond. Cette différence pourrait être due à des facteurs hormonaux, comme la sécrétion d'œstrogènes, et à des carences en fer. En France, 44% des femmes se déclarent insatisfaites de leur sommeil, contre 37% de la population générale. Elles dorment plus longtemps, en partie pour compenser une qualité de sommeil perturbée par le cycle menstruel, la ménopause, et les périodes post-grossesse. Des facteurs sociaux, comme la charge mentale et un temps de loisir plus court, contribuent également à ce besoin accru de sommeil. Le manque de sommeil chez les femmes peut affecter leur concentration, leur temps de réaction et augmenter les risques de problèmes de santé comme l'hypertension et les troubles cognitifs[12].

[12] Les femmes ont besoin de dormir plus que les hommes | Slate.fr

Conclusion

L'objectif de notre étude était de comprendre comment différents facteurs de style de vie influencent la qualité du sommeil. Notre analyse a révélé des dépendances importantes entre les habitudes quotidiennes, la santé (stress, IMC, pression artérielle, etc), les professions et la qualité du sommeil, ce qui met en exergue certains aspects pouvant affecter le repos des individus.

Nous avons utilisé différentes méthodes à l'instar de l'ACP, les régressions ou encore les tests statistiques pour mettre en lumière l'influence d'un certain nombre de caractéristiques sur la qualité du sommeil.

La régression a été utilisée dans le but d'identifier les facteurs pouvant influencer de manière significative la qualité du sommeil. Il en ressort que l'activité physique, la durée du sommeil, le niveau de stress par exemple jouent un rôle primordial dans le cadre du sommeil.

Après avoir effectué plusieurs tests, nous avons également pu relever les professions les plus atteintes par les troubles du sommeil, impactant ainsi la qualité de leur sommeil. Nous avons également obtenu des résultats pertinents en ce qui concerne le lien entre le genre et le sommeil. Ces résultats sont vérifiés par des études scientifiques, qui expliquent davantage l'origine des liens que nous avons démontrés.

En somme, notre étude a permis de mettre en évidence l'importance des facteurs de style de vie dans la qualité du sommeil. Nous avons pu identifier les comportements et les professions à risque. Il est crucial de prêter attention à ces résultats, afin de contribuer à l'amélioration de la qualité du sommeil des individus.

ANNEXES

Annexe 1:
Répartition des individus en fonction de l'IMC

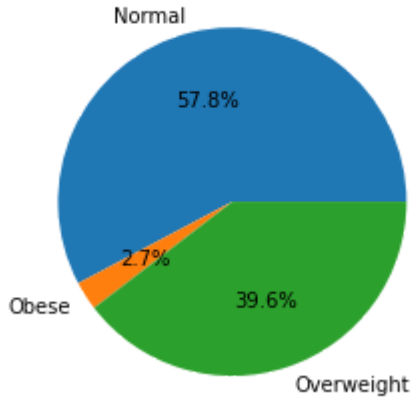

Annexe 2:
Distribution de l'Activité Physique en Minutes par Jour

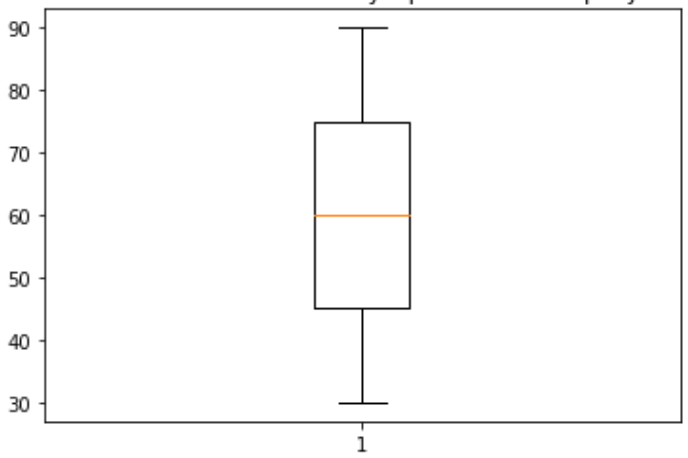

Annexe 3:
Histogramme de "Stress Level"

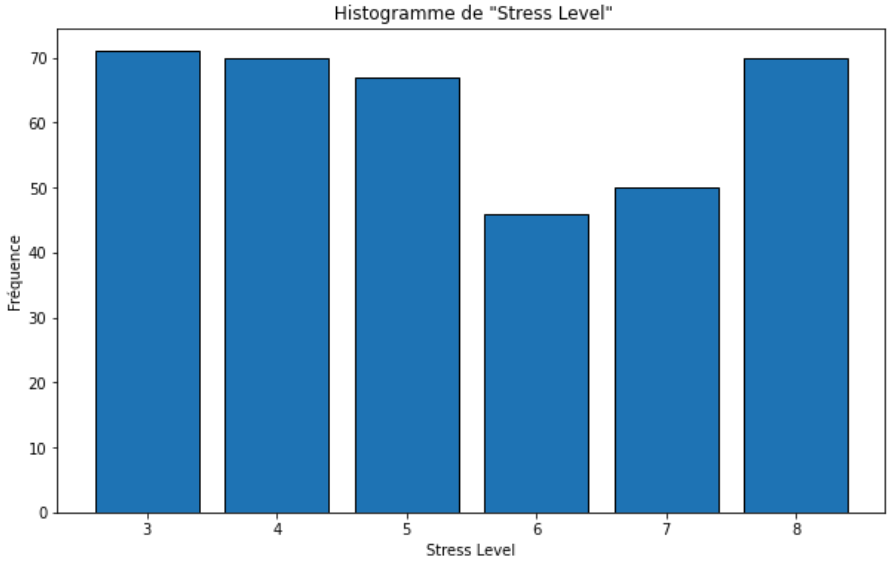

Annexe 4:
Histogramme du Nombre de Pas Quotidiens

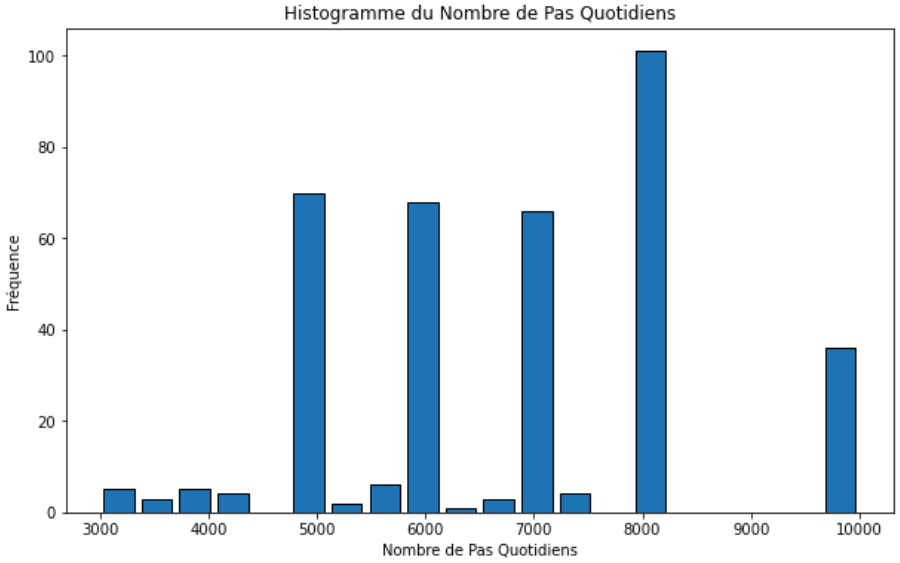

Annexe 5:

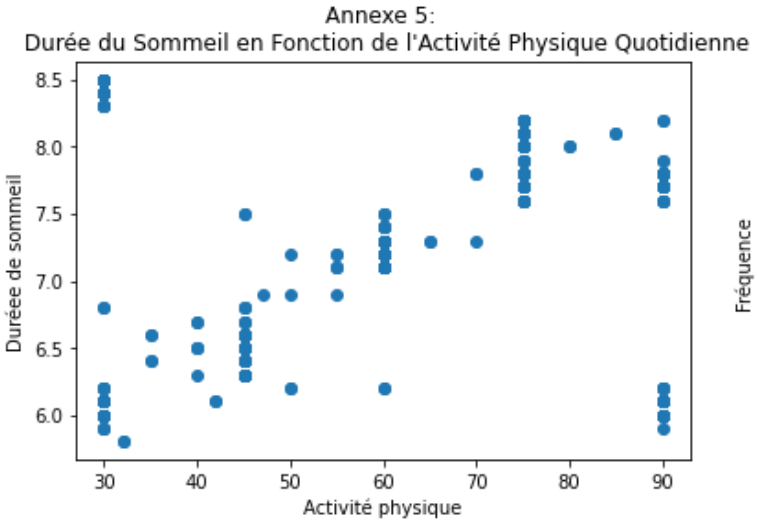

Annexe 6

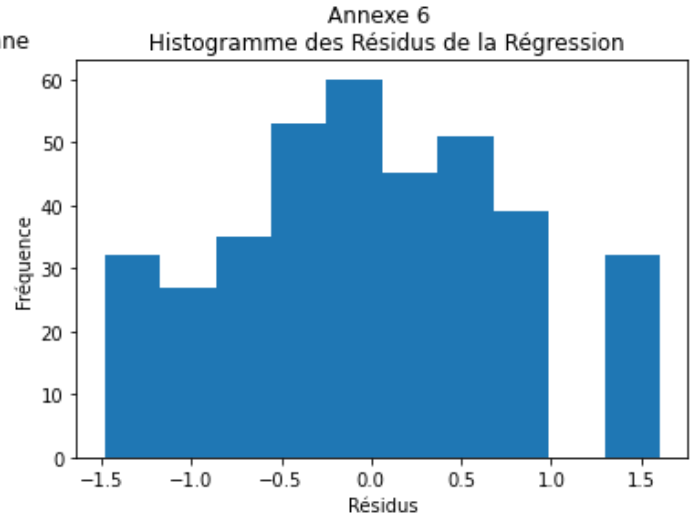
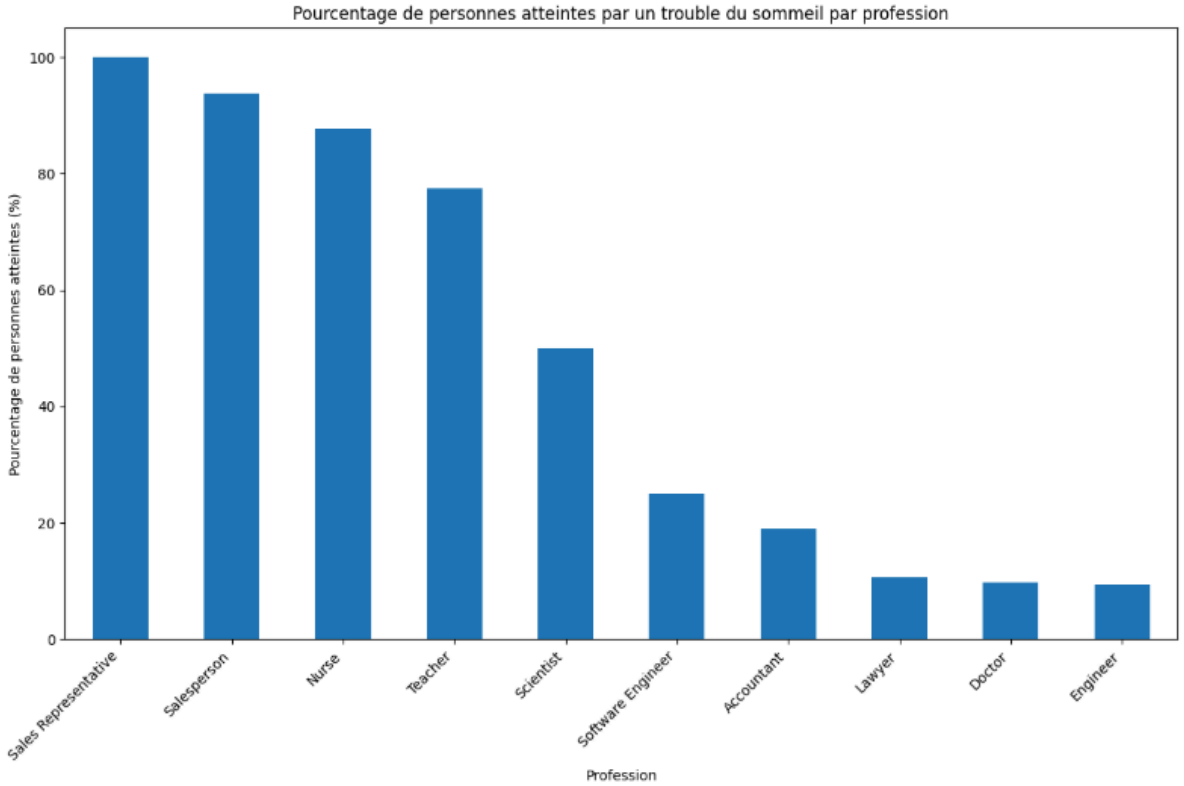
Annexe 7: